

# IoT 端末を考慮したシグナリング制御による モバイルコアノードの資源利用の効率化

安達 智哉<sup>†</sup> 阿部 修也<sup>†</sup> 長谷川 剛<sup>††</sup> 村田 正幸<sup>†</sup>

<sup>†</sup> 大阪大学大学院情報科学研究科 〒565-0871 大阪府吹田市山田丘 1-5

<sup>††</sup> 東北大学電気通信研究所 〒980-0812 宮城県仙台市青葉区片平二丁目 1 番 1 号

E-mail: <sup>†</sup>{to-adachi,s-abe,murata}@ist.osaka-u.ac.jp, <sup>††</sup>hasegawa@riec.tohoku.ac.jp

あらまし モバイルネットワーク事業者は、自身が運用するモバイルコアネットワークのノード資源が枯渇しないように、収容端末台数や接続頻度に応じて資源割り当てを行う必要がある。一方、近年増加している IoT 端末は、接続される端末の台数を予測することは困難である。また、端末の通信開始時のシグナリング手順を削減するために、RRC Connected Inactive と呼ばれる状態を導入し、端末情報をメモリに一時的に保存することが検討されている。これらのことから、今後、モバイルコアネットワークノードへの CPU やメモリ負荷が大きく変動することが予想され、効率的な資源割り当てが求められる。そこで本報告ではモバイルコアネットワークノードにおける CPU とメモリ間の負荷のオフロード手法を提案する。具体的には、ネットワークの負荷に合わせて端末の状態を制御することにより、モバイルコアネットワークノードの CPU およびメモリ負荷のバランスを調整し、収容可能な端末台数を最大化する。端末の状態制御は、端末がデータ送受信後にアイドル状態に遷移するまでの時間を制御することで実現する。提案手法により、モバイルコアネットワークノードの資源を增強することなく、収容可能な端末台数が最大で約 150% 向上することを示す。

キーワード モバイルコアネットワーク, IoT 通信, 資源割り当て, RRC Connected Inactive

## 1. ま え が き

モバイルネットワーク事業者は、自身が運用するモバイルコアネットワークのノード資源が枯渇しないように、収容端末台数や接続頻度に応じて資源割り当てを行う必要がある。主なノード資源として、CPU およびメモリが挙げられる。CPU は、アタッチやデタッチ等のシグナリングに関する通信や処理を実行するために必要とされる資源である。一方メモリは、ベアラなどの端末のセッション情報を保持するために必要とされる資源である。これらのノード資源は、モバイルコアネットワークにおける通信を実現するために必須であり、どちらか一方でも枯渇することは許されない。

一方、近年は IoT 端末の急激な増加が注目されている。IoT 端末は、スマートフォンのようなユーザ端末とは異なり、家電や自動車、電気メータ、センサなど様々な場所、様々な用途で使用される可能性があり、端末の台数およびその分布を予測することは困難である。そのため、多数の IoT 端末を収容するためにノード資源を過不足なく割り当てることは難しい。

また、IoT 端末はスマートフォン等の従来の端末とはその通信特性が異なり、データ送信に周期性や間欠性を持つという特徴がある。そのため、データ送信ごとにアイドル状態と接続状態を遷移することが予想される。その結果、端末のネットワーク接続やデータ送信に必要なシグナリングに関する通信や処理を行う、制御プレーンの輻輳が悪化すると考えられ

る。このような問題に対し、RRC Connected Inactive と呼ばれる新たな状態を導入することによって、特に IoT 端末を対象に、シグナリング手順の削減を目標とする研究が行われている [1, 2]。RRC Connected Inactive 状態とは、端末がネットワークから切り離された後も、端末のセッション情報をモバイルコアネットワークノードのメモリに保持している状態である。端末のセッション情報を破棄するアイドル状態とは異なり、モバイルコアネットワークノードのメモリ資源に負荷が発生する一方で、その端末が再び接続状態へ遷移する際に発生するシグナリング手順の一部を省略できるため、CPU 負荷の削減が可能となり、制御プレーンの輻輳の抑制が期待できる。文献 [1, 2] においては、RRC Connected Inactive を導入することにより、シグナリングオーバーヘッドの削減が可能であることが示されている。

このように、接続台数の予測が難しい IoT 端末の普及や、モバイルコアネットワークノードに与える負荷を変化させるような新たな状態の導入により、モバイルコアネットワークノードの CPU やメモリ負荷が時間的に大きく変動することが予想される。そのため、モバイルネットワーク事業者は、これまでに以上に効率的に資源割り当てを行う必要がある。

上述のような資源需要の予測が難しく、変動が激しいモバイルコアネットワークにおいて、収容可能な端末台数の増加を目的とした既存研究として、稼働するサーバやインスタンスの数を需要に応じて増減させる手法が提案されている [3-7]。しかし、そのような手法では、本来必要とされているよりも多く

の資源が供給される問題がある。なぜなら、サーバやインスタンス一台あたりの資源構成は固定であることが一般的であり、偏った資源需要に対してサーバやインスタンスを増加すると、本来増強する必要のない資源も供給されるためである。文献 [4] では、IoT 端末を収容している MME のノード台数を単純に増加すると、一部の資源が過剰に供給される可能性があることを述べている。

また、サーバの資源を効率よく活用するためにサーバの資源を分離し、各資源を個別に増強、更新可能とする Server Disaggregation アーキテクチャが提案されている [8–13]。文献 [8] では、Server Disaggregation アーキテクチャをデータセンタに適用することで、CPU やメモリなどの資源を需要に合わせて自由に組み替えることが可能になり、資源の効率的な利用が可能であることが示されている。しかし、Server Disaggregation は、年単位などの長期的なサーバ更新のためのアーキテクチャであり、本報告で対象とするような突発的な負荷変動に対応することを目的とした方式ではない。文献 [13] では、Server Disaggregation アーキテクチャを適用したシステムにおいて、細かい時間粒度で資源制御を行った場合、サーバ資源の再割り当て処理に伴う遅延やコスト面でのオーバーヘッドが大きくなることが示されている。

本報告では、モバイルコアネットワークの端末収容を対象とし、柔軟かつ効率的な、ノード資源の制御手法を提案する。具体的には、モバイルコアネットワークの負荷に応じて、端末の状態を制御することにより、モバイルコアネットワークノードのメモリおよび CPU 負荷を調整することで、収容可能な端末台数を最大化する。端末の状態の制御は、端末が最後にデータを送信したあと、Connected Inactive 状態からアイドル状態に移移するまでの時間を適応的に設定することで実現する。さらに、提案手法によるモバイルコアネットワークの性能向上に関する解析的評価を行う。具体的には、端末の通信状態に応じて発生する、モバイルコアネットワークの負荷を数学的解析によって導出し、我々の研究グループの実験結果などを用いて、定量的な評価を行う。

本報告の構成は以下の通りである。第 2 章では、本報告において評価対象となるモバイルコアネットワークの構成、シグナリング手順および端末の状態遷移について述べる。第 3 章では、提案手法について述べる。第 4 章では、数学的解析によって、モバイルコアネットワークに発生する CPU 負荷およびメモリ負荷を導出する。第 5 章では、定量的な評価を行うためのパラメータ設定を行う。第 6 章では、提案手法がモバイルコアネットワークの収容可能な端末台数に与える影響を評価する。最後に第 7 章で本報告のまとめと今後の課題について述べる。

## 2. モバイルコアネットワークアーキテクチャ

### 2.1 ネットワーク構成

図 1 にモバイルコアネットワークを示す。図中の各ノードは、以下に示す機能を持つ。

- **User Equipment (UE):** スマートフォンやタブレッ




図 1 モバイルコアネットワークモデル

ト、IoT などの端末。

- **evolved NodeB (eNodeB):** UE と無線で通信を行い、MME 及び S/PGW とシグナリングメッセージやユーザデータを交換する無線基地局。

- **Mobility Management Entity (MME):** UE やユーザの認証、UE の移動管理及びパケットの経路設定の制御などを行い、モバイルコアネットワークにおけるシグナリングに関する処理の中核となるノード。

- **Serving Gateway / Packet Data Network Gateway (S/PGW):** MME からのシグナリングメッセージに基づいて、モバイルコアネットワークと外部のネットワーク (External IP Network) を接続するノード。UE が eNodeB 間を移動した際のアンカーポイントとしても機能する。

- **Home Subscriber Server (HSS):** ユーザごとの契約情報、認証用のキーデータ及び MME のアドレスなどの情報を管理するデータベースノード。

### 2.2 シグナリング手順

図 1 のモバイルコアネットワークにおいて、UE が外部 IP ネットワークと通信する際、UE と eNodeB 間、eNodeB と S/PGW 間及び S/PGW 内にそれぞれベアラと呼ばれる論理的なトンネルを UE 毎に確立する。

UE は接続状態、アイドル状態、及び Connected Inactive 状態という 3 つの状態を持つものとする。接続状態とは、全てのベアラが確立されており、ユーザデータの送受信が可能な状態である。アイドル状態とは、ベアラを確立していない状態である。この状態では、UE の消費電力は小さいが、ユーザデータの送受信を行うためには、シグナリング手順を行い、接続状態へ遷移する必要がある。Connected Inactive 状態とは、文献 [1, 2] など近年検討されている UE の新しい状態であり、UE と eNodeB 間のベアラは解放されているが、eNodeB と S/PGW 間及び S/PGW 内のベアラは保持している状態である。この状態では、UE の消費電力は小さく、かつ、接続状態へ遷移するためのシグナリング手順を一部省略することが可能である。

図 2 に、アイドル状態及び Connected Inactive 状態から接続状態に移移するためのシグナリング手順を示す。図中の req., res., cmp., cmd., msg., ctxt はそれぞれ request, response, complete, command, message, context を意味する。また、図中で青色で示されている、5 番以降のシグナリング処理及びシグナリングメッセージは、Connected Inactive 状態から接続状態に移移する際には省略される。

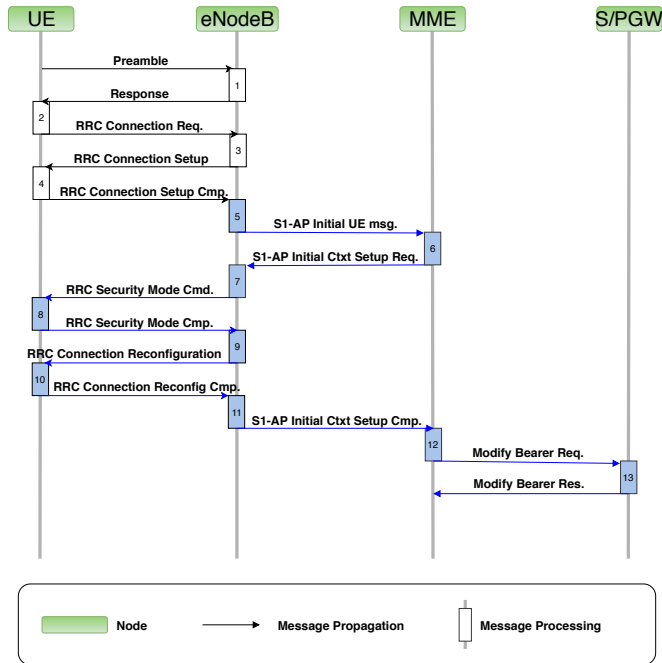


図 2 アイドル状態及び Connected Inactive 状態から接続状態へ遷移する際のシグナリング手順 [2, 14]




図 3 UE の状態遷移図

### 2.3 UE の状態遷移

UE の状態遷移図を図 3 に示す。図中の Connected, Idle, Connected Inactive は UE の状態を表し、それぞれ接続状態、アイドル状態、Connected Inactive 状態に相当する。アイドル状態の UE は、データ送信要求が発生すると接続状態へ遷移する。その後、一定期間データの送受信が発生しなければ、Connected Inactive 状態へ遷移する。Connected Inactive 状態の UE は、データ送信のタイミングで再び接続状態へ遷移する。この時、送信データ量が小さい場合は、接続状態へ遷移することなく、データ送信が行われる。これは、シグナリングのメッセージに送信データを含めることで実現される。

## 3. 提案手法

近年、モバイルコアネットワークノードの CPU やメモリ負荷が時間的に大きく変動することが予想される中、効率的な資源割り当てが求められている。そこで、本報告ではモバイルコアネットワークノードにおける CPU とメモリ間の負荷のオフロード手法を提案し、資源の利用効率の向上を図る。

図 4 に、提案手法を適用した場合における、UE の状態遷移図を示す。提案手法では、モバイルコアネットワークノードの負荷に合わせて UE の状態を制御する。具体的には、UE




図 4 提案手法適用した場合における UE の状態遷移図

が Connected Inactive 状態からアイドル状態へ遷移する条件である、アイドルタイマの値を適応的に変化させることにより、モバイルコアネットワークノードの CPU およびメモリ負荷のバランスを調整する。アイドルタイマとは、UE が最後にデータ送信を行ってからアイドル状態に遷移するまでの期間である。この期間内に次のデータ送信が発生した場合は、アイドルタイマはリセットされる。この期間内にデータ送信が発生しなかった UE は、アイドル状態へと遷移する。このアイドルタイマの値を大きくすると、UE の状態遷移を抑制できる一方、UE はより長い期間 Connected Inactive 状態に留まることになる。逆に、この値を小さくすると、UE が Connected Inactive 状態に留まる期間を短縮できる一方、UE の状態遷移が増加する。

UE の状態遷移の発生回数及び UE が Connected Inactive 状態に留まる期間は、モバイルコアネットワークノードの負荷に影響を与える。UE の頻繁な状態遷移は多くのシグナリングを発生させ、モバイルコアネットワークノードの CPU 負荷を増加させる。一方、UE が長期間 Connected Inactive 状態に留まるようになると、UE のセッション情報を保持することによるモバイルコアネットワークノードのメモリ負荷が増加する。提案手法では、アイドルタイマを適応的に設定して CPU とメモリ間で負荷をオフロードすることにより、両者の負荷を調整する。そして、モバイルコアネットワークの資源の利用効率を向上させる。

## 4. 解析

本章では、提案手法がモバイルコアネットワークの性能に与える影響を定量的に評価することを目的とし、数学的解析に基づくモバイルコアネットワークの負荷及び収容可能な端末台数の導出方法に関して説明する。

また本報告では、以下に示す仮定に基づき負荷を導出している。

- 仮定 1: データプレーンの負荷は制御プレーンの負荷と比較して十分小さい。
- 仮定 2: モバイルコアネットワークのボトルネックは MME である。
- 仮定 3: UE の通信周期は理想的に分散しており、MME に対して発生する負荷に時間的な変動はない。
- 仮定 4: データ送信にかかる時間は UE の通信周期と比べて十分小さいものとし、送信が失敗することはない。
- 仮定 5: MME 以外のノードのリソースおよびリンク帯

域は十分大きい。

仮定 1 に関しては、本報告で対象とする UE は IoT 端末であり、IoT 端末は送信データ量が小さくデータプレーンの負荷が小さい一方、シグナリングによる制御プレーンの負荷が大きいという特徴を持つ点を考慮している。また仮定 2 に関しては、MME は制御プレーンの処理の中心的役割を担うノードであり、IoT 端末を大量に収容した場合 MME がモバイルコアネットワーク中でのボトルネックになると述べられている、文献 [4] に基づいている。

#### 4.1 CPU 負荷の導出

CPU 負荷は 1 秒あたりに MME が処理するシグナリングの数を基に導出する。\$N\_{\text{UE}}\$ 台の UE がモバイルコアネットワークに存在すると仮定した時の UE の集合 \$\mathbf{U}\$ を、\$\mathbf{U} = \{u\_1, u\_2, \dots, u\_{N\_{\text{UE}}}\}\$ と定義する。ある UE \$u\_h\$ (\$u\_h \in \mathbf{U}\$) が 1 秒あたりに発生させるシグナリングの数の平均を \$c\_h\$ と定義する。Connected Inactive 状態の UE は、送信データ量が閾値より小さいとき、接続状態へ遷移せずにデータ送信を行う。UE \$u\_h\$ の送信データ量が閾値を超える確率を \$d\_h\$ とする。最後のデータ送信から Connected Inactive 状態へ遷移するまでの時間を \$T^{\text{ci}}\$、最後のデータ送信からアイドル状態へ遷移するまでの時間を \$T^{\text{i}}\$、\$u\_h\$ の通信周期を \$T\_h\$ とする。また、UE の状態遷移に伴い、MME に対して発生するシグナリングの数をそれぞれ表 1 のように定義すると、\$c\_h\$ は以下の式 (1) で表せる。ここで、以下では \$T^{\text{i}} \geq T^{\text{ci}}\$ が常に成り立つものとする。

表 1 UE の状態遷移に伴い、MME に発生するシグナリングの数

State Transition		The number of
Source	Destination	signaling occurrences
Connected	Connected	\$s_{\text{MME}}^{\text{c} \rightarrow \text{c}}\$
Connected Inactive	Connected Inactive	\$s_{\text{MME}}^{\text{ci} \rightarrow \text{ci}}\$
Connected	Connected Inactive	\$s_{\text{MME}}^{\text{c} \rightarrow \text{ci}}\$
Connected Inactive	Connected	\$s_{\text{MME}}^{\text{ci} \rightarrow \text{c}}\$
Connected Inactive	Idle	\$s_{\text{MME}}^{\text{ci} \rightarrow \text{i}}\$
Idle	Connected	\$s_{\text{MME}}^{\text{i} \rightarrow \text{c}}\$

$$c_h = \begin{cases} \frac{1}{T_h} \cdot s_{\text{MME}}^{\text{c} \rightarrow \text{c}} & \text{if } T_h \leq T^{\text{ci}} \\ \frac{1}{T_h} \cdot (s_{\text{MME}}^{\text{ci} \rightarrow \text{c}} + s_{\text{MME}}^{\text{c} \rightarrow \text{ci}}) \cdot d_h & \text{if } T^{\text{ci}} < T_h \leq T^{\text{i}} \\ \frac{1}{T_h} \cdot (s_{\text{MME}}^{\text{i} \rightarrow \text{c}} + s_{\text{MME}}^{\text{c} \rightarrow \text{ci}} + s_{\text{MME}}^{\text{ci} \rightarrow \text{i}}) & \text{otherwise} \end{cases} \quad (1)$$

本報告では \$T^{\text{i}}\$ をパラメータとして変化させるため、\$c\_h\$ を \$T^{\text{i}}\$ に関する関数として、\$c\_h(t)\$ と表す (2)。

$$c_h(t) = \begin{cases} \frac{1}{T_h} \cdot s_{\text{MME}}^{\text{c} \rightarrow \text{c}} & \text{if } T_h \leq T^{\text{ci}} \\ \frac{1}{T_h} \cdot (s_{\text{MME}}^{\text{ci} \rightarrow \text{c}} + s_{\text{MME}}^{\text{c} \rightarrow \text{ci}}) \cdot d_h & \text{if } T^{\text{ci}} < T_h \leq t \\ \frac{1}{T_h} \cdot (s_{\text{MME}}^{\text{i} \rightarrow \text{c}} + s_{\text{MME}}^{\text{c} \rightarrow \text{ci}} + s_{\text{MME}}^{\text{ci} \rightarrow \text{i}}) & \text{otherwise} \end{cases} \quad (2)$$

\$T^{\text{i}}\$ を \$t\$ とした時に、MME に対してネットワーク全体で 1 秒毎に発生するシグナリングの数の平均を \$C(t)\$ と定義する。\$C(t)\$

は \$c\_h(t)\$ を用いて以下の式 (3) で表せる。

$$C(t) = \sum_{h=1}^{N_{\text{UE}}} c_h(t) \quad (3)$$

#### 4.2 メモリ負荷の導出

UE \$u\_h\$ が接続状態である時間割合を \$\tau\_h^{\text{c}}\$、Connected Inactive 状態である時間割合を \$\tau\_h^{\text{ci}}\$、アイドル状態である時間割合を \$\tau\_h^{\text{i}}\$ と定義する。これらの値は、\$T\_h\$ および \$T^{\text{i}}\$、\$T^{\text{ci}}\$ を用いて以下の式 (4)、(5)、(6) で表せる。

$$\tau_h^{\text{c}} = \begin{cases} 1 & \text{if } T_h \leq T^{\text{ci}} \\ \frac{T^{\text{ci}}}{T_h} \cdot d_h + \frac{0}{T_h} \cdot (1 - d_h) & \text{if } T^{\text{ci}} < T_h \leq T^{\text{i}} \\ \frac{T^{\text{ci}}}{T_h} & \text{otherwise} \end{cases} \quad (4)$$

$$\tau_h^{\text{ci}} = \begin{cases} 0 & \text{if } T_h \leq T^{\text{ci}} \\ \frac{T_h - T^{\text{ci}}}{T_h} \cdot d_h + \frac{T_h}{T_h} \cdot (1 - d_h) & \text{if } T^{\text{ci}} < T_h \leq T^{\text{i}} \\ \frac{T^{\text{i}} - T^{\text{ci}}}{T_h} & \text{otherwise} \end{cases} \quad (5)$$

$$\tau_h^{\text{i}} = \begin{cases} 0 & \text{if } T_h \leq T^{\text{ci}} \\ 0 & \text{if } T^{\text{ci}} < T_h \leq T^{\text{i}} \\ \frac{T_h - T^{\text{i}}}{T_h} & \text{otherwise} \end{cases} \quad (6)$$

本報告では \$T^{\text{i}}\$ をパラメータとして変化させるため、\$\tau\_h^{\text{c}}\$、\$\tau\_h^{\text{ci}}\$、\$\tau\_h^{\text{i}}\$ を \$T^{\text{i}}\$ に関する関数としてそれぞれ \$\tau\_h^{\text{c}}(t)\$、\$\tau\_h^{\text{ci}}(t)\$、\$\tau\_h^{\text{i}}(t)\$ と表す (7)、(8)、(9)。

$$\tau_h^{\text{c}}(t) = \begin{cases} 1 & \text{if } T_h \leq T^{\text{ci}} \\ \frac{T^{\text{ci}}}{T_h} \cdot d_h + \frac{0}{T_h} \cdot (1 - d_h) & \text{if } T^{\text{ci}} < T_h \leq t \\ \frac{T^{\text{ci}}}{T_h} & \text{otherwise} \end{cases} \quad (7)$$

$$\tau_h^{\text{ci}}(t) = \begin{cases} 0 & \text{if } T_h \leq T^{\text{ci}} \\ \frac{T_h - T^{\text{ci}}}{T_h} \cdot d_h + \frac{T_h}{T_h} \cdot (1 - d_h) & \text{if } T^{\text{ci}} < T_h \leq t \\ \frac{t - T^{\text{ci}}}{T_h} & \text{otherwise} \end{cases} \quad (8)$$

$$\tau_h^{\text{i}}(t) = \begin{cases} 0 & \text{if } T_h \leq T^{\text{ci}} \\ 0 & \text{if } T^{\text{ci}} < T_h \leq t \\ \frac{T_h - t}{T_h} & \text{otherwise} \end{cases} \quad (9)$$

次に、各状態におけるメモリ負荷をそれぞれ表 2 のように定義すると、\$T^{\text{i}}\$ を \$t\$ とした時に、UE \$u\_h\$ が MME に与えるメモリ負荷の平均 \$m\_h(t)\$ は以下の式 (10) で表せる。

表 2 各状態の UE 1 台当たりが発生させる MME のメモリ負荷

state	load of MME memory
Connected	\$m_{\text{MME}}^{\text{c}}\$
Connected Inactive	\$m_{\text{MME}}^{\text{ci}}\$
Idle	\$m_{\text{MME}}^{\text{i}}\$

$$m_h(t) = m_{\text{MME}}^{\text{c}} \cdot \tau_h^{\text{c}}(t) + m_{\text{MME}}^{\text{ci}} \cdot \tau_h^{\text{ci}}(t) + m_{\text{MME}}^{\text{i}} \cdot \tau_h^{\text{i}}(t) \quad (10)$$

$T^i$  を  $t$  とした時に, MME に対してネットワーク全体で発生する平均的なメモリ負荷を  $M(t)$  と定義する.  $M(t)$  は  $m_h(t)$  を用いて以下の式 (11) で表せる.

$$M(t) = \sum_{h=1}^{N_{UE}} m_h(t) \quad (11)$$

#### 4.3 収容可能な端末台数の導出

CPU が 1 秒あたりに処理できるシグナリングの数の最大値及びメモリのサイズをそれぞれ  $C^{\max}$ ,  $M^{\max}$  とする. この時, 以下の式 (12) に示した 2 つの条件を同時に満たすような  $t$  の値が存在するならば,  $T^i$  を  $t$  に設定することによって, 与えられた UE は全て収容可能である.

$$\begin{aligned} C(t) &\leq C^{\max} \\ M(t) &\leq M^{\max} \end{aligned} \quad (12)$$

収容可能な端末台数は, 条件 (12) を満たす  $t$  の値が存在するような UE の台数の最大値である.

### 5. パラメータ設定

### 6. 評価結果と考察

### 7. まとめと今後の課題

#### References

- [1] S. Hailu, M. Saily, and O. Tirkkonen, "RRC State Handling for 5G," *IEEE Communications Magazine*, vol. 57, no. 1, pp. 106–113, Jan. 2019.
- [2] I. L. Da Silva, G. Mildh, M. Saily, and S. Hailu, "A Novel State Model for 5G Radio Access Networks," in *Proceedings of 2016 IEEE International Conference on Communications Workshops (ICC)*, May 2016, pp. 632–637.
- [3] M. Shimizu, H. Nakazato, and H. Seshake, "Scale-Out Architecture for Service Order Processing Systems," in *Proceedings of 2013 IFIP/IEEE International Symposium on Integrated Network Management (IM 2013)*, May 2013, pp. 880–883.
- [4] P. C. Amogh, G. Veeramachaneni, A. K. Rangiseti, B. R. Tamma, and A. A. Franklin, "A Cloud Native Solution for Dynamic Auto Scaling of MME in LTE," in *Proceedings of 2017 IEEE 28th Annual International Symposium on Personal, Indoor, and Mobile Radio Communications (PIMRC)*, Oct. 2017, pp. 1–7.
- [5] I. Alawe, Y. Hadjadj-Aoul, A. Ksentini, P. Bertin, and D. Darche, "On the Scalability of 5G Core Network: The AMF Case," in *Proceedings of 2018 15th IEEE Annual Consumer Communications Networking Conference (CCNC)*, Jan. 2018, pp. 1–6.
- [6] Y. Ren, T. Phung-Duc, J. Chen, and Z. Yu, "Dynamic Auto Scaling Algorithm (DASA) for 5G Mobile Networks," in *Proceedings of 2016 IEEE Global Communications Conference (GLOBECOM)*, Dec. 2016, pp. 1–6.
- [7] C. H. T. Arteaga, F. Rissoi, and O. M. C. Rendon, "An Adaptive Scaling Mechanism for Managing Performance Variations in Network Functions Virtualization: A Case Study in an NFV-Based EPC," in *Proceedings of 2017 13th International Conference on Network and Service Management (CNSM)*, Nov. 2017, pp. 1–7.
- [8] M. Mahloo, J. M. Soares, and A. Roozbeh, "Techno-Economic Framework for Cloud Infrastructure: A Cost Study of Resource Disaggregation," in *Proceedings of 2017 Federated Conference on Computer Science and Information Systems (FedCSIS)*, Sep. 2017, pp. 733–742.
- [9] "Intel's Disaggregated Server Rack," Moor Insights Strategy, Technical Report (TR), Aug. 2013.
- [10] C. Devaki and L. Rainer, "Enhanced Back-off Timer Solution for GTP-C Overload Control," Feb. 2016. [Online]. Available: <http://www.freepatentsonline.com/y2016/0057652.html>
- [11] B. Abali, R. J. Eickemeyer, H. Franke, C. Li, and M. Taubenblatt, "Disaggregated and Optically Interconnected Memory: When will it be cost effective?" *CoRR*, vol. abs/1503.01416, 2015. [Online]. Available: <http://arxiv.org/abs/1503.01416>
- [12] "Disaggregated Servers Drive Data Center Efficiency and Innovation," Intel Corporation, Technical Report (TR), Jun. 2017.
- [13] S. Legtchenko, H. Williams, K. Razavi, A. Donnelly, R. Black, A. Douglas, N. Cheriére, D. Fryer, K. Mast, A. D. Brown, A. Klimovic, A. Slowey, and A. Rowstron, "Understanding Rack-Scale Disaggregated Storage," in *Proceedings of 9th USENIX Workshop on Hot Topics in Storage and File Systems (HotStorage 17)*. Santa Clara, CA: USENIX Association, 2017. [Online]. Available: <https://www.usenix.org/conference/hotstorage17/program/presentation/legtchenko>
- [14] 3GPP, "Study on architecture enhancements for Cellular Internet of Things (CIoT)," 3rd Generation Partnership Project (3GPP), Technical Report (TR) 23.720, Mar. 2016, version 13.0.0. [Online]. Available: <https://portal.3gpp.org/desktopmodules/Specifications/SpecificationDetails.aspx?specificationId=2894>